

# Tarea III

Rayan García Fabián 144424, Bernardo Mondragon Brozon 143743, Karen DElgado Curiel 142252, Diego Garcia 14xxxx

1 October 2018

## Problema 1

Un estadístico está interesado en el número  $N$  de peces en un estanque. Él captura 250 peces, los marca y los regresa al estanque. Unos cuantos días después regresa y atrapa peces hasta que obtiene 50 peces marcados, en ese punto también tiene 124 peces no marcados (la muestra total es de 174 peces).

- ¿Cuál es la estimación de  $N$ ?
- Haga un programa, que permita simular el proceso de obtener la primera y segunda muestra considerando como parámetros el tamaño  $N$  de la población de interés, el tamaño de la primera y segunda muestra y como datos a estimar son: de qué tamaño debe ser  $n_1$  y  $n_2$  para obtener una buena aproximación y ver cómo se afecta por el tamaño  $N$ .

### Solución:

Primero definamos la notación a usar. Consideremos  $N$  como el número de peces en la población,  $n_1$  el número de peces marcados en la primer muestra,  $n_2$  el número de peces capturados en la segunda muestra y  $r$  el número de animales de la segunda muestra que están marcados. Sabemos que  $N = 174$ ,  $n_1 = 250$ ,  $n_2 = 174$ ,  $r = 50$ . Entonces por el método de Lincoln–Petersen, suponiendo que no cambió la población de peces entre el momento de la primera y segunda muestra, se estima que  $\hat{N} = \frac{n_1 n_2}{r}$ , sustituyendo valores  $\hat{N} = 870$ .


```
Simulacion_Peces<-function(N,n1,n2){ #Función para simular el proceso de obtener la primera y segunda muestra
  pecesM<-c(rep("M",n1))
  pecesT<-c(pecesM,c(rep("NM",N-n1)))
  muestra2<-sample(pecesT,n2)
  r<-length(subset(muestra2,muestra2=="M"))
  N_est<-(n1*n2)/(r+1) #Ojo aquí consideramos r+1 ya que como no asignamos probabilidades a la muestra,
  return(N_est)
}

#Supongamos N=10000, vamos a ver de qué tamaño deben ser n1 y n2 para obtener una buena estimación de N
N<-10000
n1<-c(seq(20,1000,by=5))
n2<-c(seq(10,990,by=5))

M_est<-c()
for (i in 1:length(n1)){
  M_est[i]<-Simulacion_Peces(N,n1[[i]],n2[[i]])
}

plot(n1[1:length(n1)],M_est[1:length(n1)],type = "l",col="blue",main = "Estimación de N", xlab = "n1",y
```

## Estimación de N



■

## Problema 2

Este problema es una versión simplificada de dos problemas comunes que enfrentan las compañías de seguros: calcular la probabilidad de quebrar y estimar cuánto dinero podrán hacer.

Supongan que una compañía de seguros tiene activos (todo en dólares) por \$1000000. Tienen  $n = 1000$  clientes que pagan individualmente una prima anual de \$5500 al principio de cada año. Basándose en experiencia previa, se estima que la probabilidad de que un cliente haga un reclamo en el año es de  $p = 0.1$ , independientemente del número de reclamos previos de otros clientes. El tamaño  $X$  de los reclamos varía y tiene la siguiente distribución de probabilidad:

$$f_X(x) = \frac{\alpha\beta^\alpha}{(x+\beta)^{\alpha+1}} I_{[0,\infty)}(x)$$

con  $\alpha = 5$  y  $\beta = 125000$  (Tal  $X$  tiene una distribución Pareto, la cual es frecuentemente usada para modelar el monto de un siniestro). Suponemos las fortunas de la compañía aseguradora sobre un horizonte de 5 años. Sea  $Z(t)$  el valor de los activos de la compañía al final del  $t$ -ésimo año, de manera que  $Z(0) = 1000000$  y

$$Z(t) = \max(Z(t-1) + P(t) - S(t), 0)$$

donde  $P(t)$  es el monto de las primas pagadas durante el  $t$ -ésimo año y  $S(t)$  es el monto de los siniestros pagados durante el  $t$ -ésimo año. Notar que si  $Z(t)$  cae bajo 0, entonces la compañía se va a la bancarrota y deja de operar.

1. Calcular  $F_X(x)$ ,  $E(X)$  y  $Var(X)$ . Obtener por simulación una muestra de  $X$  y hallar los valores estimados de las cantidades anteriores y compararlos con los valores teóricos.
2. Escriban una función para simular los activos de la compañía por cinco años y estimar lo siguiente: (1) La probabilidad de que la compañía se vaya a la bancarrota. (2) Los activos esperados al final del quinto año.
3. Si el valor de los activos rebasan la cantidad de \$1000000, entonces el excedente se reparte entre los accionistas como dividendos de manera que si  $D(t)$  son los dividendos pagados al final del  $t$ -ésimo año, entonces

$$D(t) = \begin{cases} 1000000 - Z(t) & \text{si } Z(t) > 1000000 \\ 0 & \text{si } Z(t) \leq 1000000 \end{cases}.$$

Bajo este nuevo esquema, estimar (1) la probabilidad de irse a la quiebra, (2) los activos esperados después de 5 años, y (3) las ganancias totales esperadas después de 5 años de operación.

**Solución:**

$$F_X = \int_0^x \frac{\alpha\beta^\alpha}{(s+\beta)^{\alpha+1}} ds = \alpha\beta^\alpha \int_0^x \frac{1}{(+\beta)^{\alpha+1}} ds = \alpha\beta^\alpha \int_\beta^{\beta+x} \frac{1}{u^{\alpha+1}} du = \alpha\beta^\alpha \left( \frac{-u^{-\alpha}}{\alpha} \right) \Big|_\beta^{\beta+x} = 1 - \left( \frac{\beta}{\beta+x} \right)^\alpha$$

Para el cálculo de la esperanza notemos que  $X$  es una v.a no negativa, entonces se puede proceder de manera más sencilla por medio de la función de supervivencia  $S(x) = 1 - F_X(x)$

$$E[X] = \int_0^\infty x(1 - F_X(x)) dx = \int_0^\infty \frac{\beta^\alpha}{(x+\beta)^\alpha} dx = \frac{\beta}{\alpha-1}$$

De manera alternativa podemos considerar a  $Y$  distribuida Pareto del tipo I, sabemos que  $E[Y] = \frac{\alpha\beta}{\alpha-1}$ . Entonces sea  $X = Y - \beta$ , se tiene que  $E[X] = E[Y] - \beta = \frac{\alpha\beta}{\alpha-1} - \beta$ .


Partiendo de la transformación anterior se tiene que  $Var(X) = Var(Y) = \frac{\alpha^2}{(\alpha-1)^2(\alpha-2)}$ ;  $\alpha > 2$ .

Ahora obtendremos por medio de simulación una muestra de  $X$  y su función de distribución

```
Pareto_Lomax<-function(a,b,n){
  u<-runif(n)
  Lomax_MA<-c()
  for (i in 1:n) {
    Lomax_MA[i]<-(b*(1-(1-u[[i]])^(1/a)))/((1-u[[i]])^(1/a))
  }
  return(Lomax_MA)
}

hist(Pareto_Lomax(2,125000,1000),main = "Histograma de X",xlab = "",ylab = "Frecuencia")
```

## Histograma de X



Realizamos la simulación de los activos de la compañía en un horizonte de cinco años. Supondremos además que la aseguradora siempre renueva la póliza con el cliente, esto es que una vez que un cliente reclama se le vuelve a vender la póliza al año siguiente.

```
registro<-function(activos,prima,n_clientes,prob_reclamo){
registro_activos<-c()
registro_activos[1]<-activos
for (i in 2:6) {
reclamos<-rbinom(n_clientes,1,prob_reclamo)
monto_reclamos<-Pareto_Lomax(5,125000,sum(reclamos))
registro_activos[i]<-registro_activos[i-1]-sum(monto_reclamos)+n_clientes*prima
if(registro_activos[i-1]<=0){
registro_activos[i]<-0
}
}
return(registro_activos)
}

activos<-10e6
prima<-5500
n_clientes<-1000
prob_reclamo<-0.1

huella<-matrix(,100,6)
for (i in 1:100) {
huella[i,]<-registro(activos =activos, prima = prima, n_clientes = n_clientes,prob_reclamo = prob_rec
```

```
colnames(huella)<-c("z(0)","z(1)","z(2)","z(3)","z(4)","z(5)")
huella<-as.data.frame(huella)
head(huella)
```

```
##      z(0)      z(1)      z(2)      z(3)      z(4)      z(5)
## 1 1e+07 12548075 13976788 16543196 19472773 22381244
## 2 1e+07 12214902 14441210 16571760 18617982 21097751
## 3 1e+07 11925108 15085942 17092351 18583744 20916652
## 4 1e+07 12014988 14589950 17216427 18914342 21526591
## 5 1e+07 13451610 15063574 17738627 20161389 22341663
## 6 1e+07 12331325 14905310 17852281 21056026 22885175
```

Notemos que hasta el momento no hemos visto ningún caso de ruina. Estudiemos un esquema en el que si el registro de activos en el periodo excede cierta cantidad, entonces se recompensa a los accionistas.

```
registro_acc<-function(activos,prima,n_clientes,prob_reclamo){
registro_activos<-c()
registro_activos[1]<-activos
for (i in 2:6) {
reclamos<-rbinom(n_clientes,1,prob_reclamo)
monto_reclamos<-Pareto_Lomax(5,125000,sum(reclamos))
if(registro_activos[i-1]<=0){
registro_activos[i:6]<-0
}
else if(registro_activos[i-1]>1000000){
registro_activos[i]<-registro_activos[i-1]-(10e6)-sum(monto_reclamos)+n_clientes*prima
}
else{registro_activos[i]<-registro_activos[i-1]-sum(monto_reclamos)+n_clientes*prima
}
}
return(registro_activos)
}
```

```
activos<-10e6
prima<-5500
n_clientes<-1000
prob_reclamo<-0.1
```

```
huella<-matrix(,100,6)
for (i in 1:100) {
huella[i,]<-registro_acc(activos =activos, prima = prima, n_clientes = n_clientes,prob_reclamo = prob.
}
```

```
colnames(huella)<-c("z(0)","z(1)","z(2)","z(3)","z(4)","z(5)")
huella<-as.data.frame(huella)
head(huella)
```

```
##      z(0)      z(1)      z(2) z(3) z(4) z(5)
## 1 1e+07 2757089 -5353393    0    0    0
## 2 1e+07 2696072 -5523657    0    0    0
## 3 1e+07 2134274 -5904789    0    0    0
## 4 1e+07 2444245 -5338381    0    0    0
## 5 1e+07 2820087 -4996092    0    0    0
## 6 1e+07 1471575 -6541724    0    0    0
```

Notemos que bajo este esquema en el que los accionistas son recompensados, la probabilidad de quiebra es 1.


### Problema 3

Proponer algoritmos (método y pseudocódigo o código, así como una corrida) para generar muestras de las siguientes densidades.

\*Cauchy  $f(x) = \frac{1}{\pi\beta[1+(\frac{x-\gamma}{\beta})^2]}$ ;  $\gamma, x \in \mathbb{R}; \beta > 0$

**Solución:** Podemos encontrar la distribución de X como  $F_X(x) = \frac{\arctan(\frac{x-\gamma}{\beta})}{\pi} + \frac{1}{2}$ , entonces  $F^{-1}(u) = \tan(\pi(u - \frac{1}{2}))$ . Usamos el método de la transformada inversa

```
cauchy<-function(gamma,beta,n){
u<-runif(n)
u<-tan(pi*u)*beta+gamma
return(u)
}
x<-1:100
hist(cauchy(0,1,5000),probability=T,breaks=100,main = "Cauchy(0,1) n=5000",ylab = "",xlab = "")
curve(dcauchy(x),add=T,from=-100,to=100)
```




```
U<- numeric(1000)
n<-1000
prom<-numeric(n)
y<-c()
```

```

for (i in 1:n) {
  u<-runif(1000)
  x<-tan(pi*(u-0.5))
  prom[i]<-mean(x)
}
plot(1:n,prom[1:n],type="l",lwd=2,col="blue",main = "Media distribución Cauchy")

```

## Media distribución Cauchy



\*Gumbel  $f(x) = \frac{1}{\beta} \exp \left[ -e^{-\frac{(x-\gamma)}{\beta}} - \frac{x-\gamma}{\beta} \right]; \gamma, x \in \mathbb{R}; \beta > 0$ .


**Solución:**

```

gumbel<-function(gamma,beta,n){
  unif<-runif(n)
  unif<-beta*log(-log(unif))+gamma
  return(unif)
}
hist(gumbel(0,1,5000),probability =T,breaks=60,xlab = "",ylab="",main = "Distribución Gumbel")

```

## Distribución Gumbel




```
n_s<-c(seq(50,5000,by=50))
X_est<-c()
for (i in 1:length(n_s)) {
  X_est[i]<-sum(gumbel(0,1,n_s[i]))/n_s[i]
}

plot(n_s[1:length(n_s)],X_est[1:length(n_s)],type = "l",col="blue", xlab = "n",ylab = "Xest",main="Medi
```



## Media Gumbel



\*Logística

$$f_X(x) = \frac{e^{-\frac{x-\gamma}{\beta}}}{\beta \left(1 + e^{-\frac{x-\gamma}{\beta}}\right)^2} \quad \text{con } \gamma, x \in \mathbb{R} \text{ y } \beta > 0$$


**Solución:**

Para esto utilizaremos el hecho de que si  $X \sim U(0, 1)$ , entonces  $\gamma + \beta(\log(X) - (1 - X)) \sim \log(\gamma, \beta)$

```
Dist_logistica<-function(n,g,b){
  u<-runif(n)
  x<-g+b*(log(u)-1+u)
  return(x)
}
```

```
hist(Dist_logistica(5000,0,1),probability =T,breaks=60,main = "Distribución logística",xlab = "",ylab =
```


## Distribución logística



```
n_s<-c(seq(50,5000,by=50))
X_est<-c()
for (i in 1:length(n_s)) {
  X_est[i]<-sum(Dist_logistica(n_s[i],0,1))/n_s[i]
}

plot(n_s[1:length(n_s)],X_est[1:length(n_s)],type = "l",col="blue", xlab = "n",ylab = "Xest",main="Medi
```

## Media distribución logística



\*Pareto  $f(x) = \frac{\alpha_2 c^{\alpha_2}}{x^{\alpha_2+1}}; c > 0, \alpha_2 > 0, x > c$ .

**Solución:**

$$F_X = \int_c^x \frac{\alpha_2 c^{\alpha_2}}{s^{\alpha_2+1}} ds = \alpha_2 c^{\alpha_2} \frac{s^{-\alpha_2}}{-\alpha_2} \Big|_c^x = 1 - \left(\frac{c}{x}\right)^{\alpha_2}$$


.

$$F^{-1}(u) = \frac{c}{(1-u)^{\frac{1}{\alpha_2}}}$$

```
S_pareto<-function(n,c,alfa){
  u<-runif(n)
  x<-c/(1-u)^(1/alfa)
  return(x)
}
```

```
hist(S_pareto(5000,1,2),probability =T,breaks=60,main = "Distribución Pareto",xlab = "",ylab = "")
```


## Distribución Pareto



```
n_s<-c(seq(50,5000,by=50))
X_est<-c()
for (i in 1:length(n_s)) {
  X_est[i]<-sum(S_pareto(n_s[i],1,2))/n_s[i]
}

plot(n_s[1:length(n_s)],X_est[1:length(n_s)],type = "l",col="blue", xlab = "n",ylab = "Xest", main="Med
```

## Media distribución Pareto



## Problema 4

Grafiquen las siguientes densidades. Dar los algoritmos de transformación inversa, composición y aceptación-rechazo para cada una de las siguientes densidades. Discutir cuál algoritmo es preferible para cada densidad.

$$f(x) = \frac{3x^2}{2} I(x)_{[-1,1]}$$

$$f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{x}{a(1-a)}, & 0 \leq x \leq a \\ \frac{1}{1-a}, & a \leq x \leq 1-a \\ \frac{1-x}{a(1-a)}, & 1-a \leq x \leq 1 \\ 0, & x \geq 1 \end{cases}$$

**Solución:**

```
ind<-function(x,a,b){
  ifelse(x<=b & x>= a,1,0)
}



f1<-function(x){
  (3*(x^2)/2)*ind(x,-1,1)
}
```

```

F1<-function(x){
  ifelse(x<=-1,0,ifelse(x<=1,0.5*(x^3+1),1))
}

x<-seq(-1.5,1.5,length=200)
par(mfrow=c(1,2))
plot(x,f1(x),type="l",main="f1(x)")
plot(x,F1(x),type = "l",main = "F1(x)")

```




```

f2<-function(x,a=0.25){
  ind(x,-1,1)*(ind(x,0,a)*(x/(a*(1-a)))+ind(x,a,1-a)/(1-a)+ind(x,1-a,1)*((1-x)/(a*(1-a))))
}

F2<-function(x,a=0.25){
  ind(x,0,a*x^2/(2*a*(1-a)))+(x-a/2)/(1-a)*ind(x,a,1-a)+((1-3*a/2)/(1-a)+(x*(1-x/2)-(1-a)*(1+a)/2)/(a*(1-a)
}

par(mfrow=c(1,2))
x<-seq(-1.1,1.1,length=200)
plot(x,f2(x),type="l",main="f2(x)")
plot(x,F2(x),type="l",main="F2(x)")

```



## Problema 5

Considerando la transformación polar de Marsaglia para generar muestras de normales estándar, muestren que la probabilidad de aceptación de  $S = V_1^2 + V_2^2$  en el paso 2 es  $\frac{\pi}{4}$ . Encuentre la distribución del número de rechazos de S antes de que ocurra una aceptación. ¿Cuál es el número esperado de ejecuciones del paso 1?

**Solución:**

Notemos que gráficamente estamos trabajando con un círculo unitario dentro de un cuadrado de  $1 \times 1$ , se acepta si  $S = V_1^2 + V_2^2$  cae dentro del círculo, y se rechaza si cae en el área restante. Entonces la probabilidad de aceptación es el área del círculo unitario  $A = \frac{\pi r^2}{2} = \frac{\pi}{4}$ . Para modelar la distribución del número de rechazos de S antes de una aceptación, basta con definir  $X \sim \text{Geo}(p)$  donde  $p$  es la probabilidad de aceptación, en este caso  $\frac{\pi}{4}$ . Finalmente  $E[X] = \frac{1-p}{p} = 3\pi$ .

## Problema 6

Obtengan una muestra de 1,000 números de la siguiente distribución discreta, para  $k = 100$ .

$$p(x) = \frac{2x}{k(k+1)}; x = 1, 2, \dots, k$$


**Solución:**

```
x <-sample(1:100,size=1000,replace=T,prob=c(seq(1:100)*(2/10100)))
x[1:50]

## [1] 100 83 43 40 93 100 79 73 83 52 60 98 50 40 50 31 92
## [18] 92 14 88 38 24 85 94 97 60 100 82 86 58 67 31 100 93
## [35] 60 98 100 92 82 62 82 68 80 65 100 98 33 100 74 72

hist(x,main = "Histograma distribución discreta",ylab = "")
```

## Histograma distribución discreta



## Problema 7

Desarrollen un algoritmo para generar una variable aleatoria binomial, usando la técnica de convolución (Hint: ¿cuál es la relación entre la distribución binomial y Bernoulli?). Generar una muestra de 100,000 números. ¿Qué método es más eficiente, el de convoluciones o la función rbinom en R?

```
s_Binom<-function(n,t,p){
  esp_muestral<-c(0,1)
  muestra_Binom<-c()
  for (i in 1:n) {
    muestra_Binom[i]<-sum(sample(esp_muestral,t,replace = TRUE,prob = c(p,1-p)))
  }
  return(muestra_Binom)
}
```

```
ptm <- proc.time()
prueba1<-s_Binom(1,100000,0.4)
```



```
proc.time()-ptm
```

```
##      user  system elapsed  
##      0.02    0.00    0.02
```

```
ptm<-proc.time()  
prueba2<-rbinom(1,100000,0.4)  
proc.time()-ptm
```

```
##      user  system elapsed  
##         0         0         0
```

Resulta más eficiente realizar una muestra de 100000 números con la función rbinom.


## Problema 8

Para un proceso Poisson no homogéneo con función de intensidad dada por:

$$\lambda(t) = \begin{cases} 5, t \in (1, 2], (3, 4], (5, 6] \dots \\ 3, t \in (0, 1], (2, 3], (4, 5] \dots \end{cases}$$

```
lambdat<-function(t){  
x<-paste("", "{", 0, "<=t & t<", "1, }", sep="")  
for(i in seq(2,100,2)){  
x<-paste(x, paste("", "{", i, "<=t & t <", "1+i, }", sep=""), sep="|")  
}  
return(ifelse(eval(parse(text=0))), 3, 5))  
}  
poissonnohomogeneo<-function(lambdat, n, pic=T){  
  lambda<-5  
  TT<-rexp(n, lambda)  
  s<-cumsum(TT)  
  u<-runif(n)  
  ss<-s[u<=lambdat(s)/lambda]  
  Ns<-1:length(ss)  
  if(pic==T){  
    plot(ss, Ns, type="s", xlab="", ylab="N(t)", main="Proceso Poisson no homogéneo")  
    return(list(ss, cuenta=Ns))  
  }  
}  
poissonnohomogeneo(lambdat, 510)
```

## Proceso Poisson no homogéneo



```
## [[1]]
## [1] 0.1280520 0.1909469 0.2018692 0.2886050 0.3527976
## [6] 0.6972334 0.9343731 1.3491755 1.3882512 1.5267786
## [11] 1.7026017 2.0131258 2.0188787 2.1071274 2.3886846
## [16] 2.6219660 2.7626154 3.1184214 3.3461138 3.3760219
## [21] 3.4429080 3.6033026 3.6444879 3.7268862 4.0303768
## [26] 4.1577946 4.3183193 4.6782262 5.0762049 5.1485966
## [31] 5.3604027 5.5803791 5.9079134 6.1160567 6.3142143
## [36] 6.5574760 6.5861310 6.6740659 6.7421442 6.8661431
## [41] 6.8812560 6.9025767 6.9245331 7.0680662 7.3296229
## [46] 7.4865644 7.5885928 7.6896516 7.8587671 7.8809484
## [51] 8.1045560 8.1282745 8.4422876 8.5068105 8.6346657
## [56] 8.8898060 9.1109734 9.2381594 9.2749087 9.6819525
## [61] 9.7422137 10.1303134 10.2184650 10.6005279 10.7851668
## [66] 11.0280500 11.0294486 11.1974730 11.4864799 11.5576631
## [71] 11.7486928 11.8749495 11.9519603 12.1379569 12.3223888
## [76] 12.4109081 12.6326941 12.6562538 12.6642385 12.6716976
## [81] 12.9573441 13.0676400 13.4098783 13.6477520 13.9583168
## [86] 14.0234982 14.0738265 14.0832463 14.3750912 14.4154878
## [91] 14.4610227 14.8515033 15.1037292 15.1597050 15.3089607
## [96] 15.8142284 16.0195002 16.2917966 16.3135627 16.4060348
## [101] 16.4657119 16.5144311 16.5616343 16.7178627 16.9189601
## [106] 16.9213000 17.3219261 17.3271457 17.5413295 17.8239641
## [111] 18.0077561 18.0582275 18.2108466 18.2154198 18.2855076
## [116] 18.4790534 18.5937588 18.6332882 18.6556256 19.3588817
## [121] 19.5238455 19.6521607 19.9622942 20.1323625 20.1929366
```

## [126]	20.3064969	20.4617435	20.5663910	20.6146392	20.6977192
## [131]	20.9725404	21.2814157	21.7192945	21.8206376	22.1959365
## [136]	22.3864260	22.9193168	23.9383233	23.9545371	24.0634560
## [141]	24.4081983	24.6484019	25.0764038	25.1237362	25.3047902
## [146]	25.4479303	25.6288436	25.7464225	26.0029393	26.0273366
## [151]	26.1985436	26.2692002	26.2911804	26.2991550	26.4306472
## [156]	26.5052715	26.5263524	26.6003811	26.7776113	26.8451315
## [161]	27.1320819	27.3687802	27.3713284	27.3786130	27.6900640
## [166]	28.2649095	28.5391911	29.0173126	29.0616521	29.0717444
## [171]	29.6745789	30.0177735	30.0277551	30.0984217	30.1621517
## [176]	30.3907296	30.4898965	30.6478508	30.6745917	31.0357585
## [181]	31.2322692	31.5271323	31.6035701	31.6562604	31.9280608
## [186]	32.1708551	32.1878656	32.2799917	32.3589696	32.4912019
## [191]	32.6070173	32.6289198	32.7080573	32.7492372	33.1744477
## [196]	33.5329945	34.3471726	34.4144675	34.4164050	34.6145903
## [201]	34.9268027	35.5310296	35.6902531	36.3074221	36.3924322
## [206]	37.5010062	37.7004841	37.9291091	38.3379086	38.3974002
## [211]	38.5000106	38.9723726	38.9792315	39.3527280	39.4712931
## [216]	39.8670913	39.9562924	40.1048564	40.2997508	40.6021705
## [221]	41.0546981	41.4106177	41.8510100	42.3357010	42.3381400
## [226]	42.9537777	43.2249013	43.3847074	44.1668193	44.2649808
## [231]	44.4874104	44.5324880	44.6530667	44.8178544	45.0623517
## [236]	45.1688482	45.1871707	45.5321854	45.8008854	45.8144220
## [241]	46.0411474	46.0890733	46.1826277	46.7712661	46.8288990
## [246]	46.8639178	46.8715279	47.1364257	47.3381485	47.4763582
## [251]	47.9304531	47.9746846	48.0554283	48.2995199	48.4358465
## [256]	49.3627461	49.3820738	49.5548392	49.6436427	49.9941435
## [261]	50.0942861	50.3842954	50.7248321	51.0891882	51.1516759
## [266]	51.3071666	51.4235651	51.6452067	51.6966591	51.7398145
## [271]	51.7794947	51.8996110	52.2457886	52.3462727	52.8662579
## [276]	53.0534261	53.4012727	53.4340198	53.9020016	54.0103796
## [281]	54.2480229	54.2578996	54.2679492	54.4712324	54.5139952
## [286]	54.5345046	54.7489235	54.9141990	54.9154537	54.9854461
## [291]	55.0097511	55.2773114	55.5166191	55.5373342	55.6449041
## [296]	55.8382418	56.2481031	56.3908016	56.4587499	56.5709993
## [301]	56.7405586	56.9116677	57.1670995	57.2539073	57.2813621
## [306]	57.8800489	58.4727863	58.5153685	58.7850066	58.8246368
## [311]	58.9330130	58.9757796	59.0805129	59.1975602	59.5560414
## [316]	59.8932023	59.9049681	59.9413303	60.0224449	60.0703212
## [321]	60.0914452	60.2435199	60.2443976	60.5333570	60.5536027
## [326]	60.6936097	60.8131112	60.9108123	61.2844361	61.2868254
## [331]	61.3036264	61.9635232	62.4166117	63.0424104	64.0819858
## [336]	64.2308019	64.7873308	64.8839302	65.7329613	65.8088633
## [341]	66.0200505	66.1386693	66.5723584	66.6289431	66.8227071
## [346]	66.8777615	66.9118167	67.1265731	67.1355034	67.3159328
## [351]	67.4017351	67.5056031	67.9793572	68.0065820	68.2144720
## [356]	68.4509148	68.7278734	68.8568274	69.2310945	69.2615850
## [361]	69.5308375	69.6397721	69.7801382	69.9245624	69.9634514
## [366]	70.9251441	71.6979269	71.6993437	71.7790529	71.9844713
## [371]	71.9847270	72.3157340	72.4622009	72.7558676	72.8141824
## [376]	73.3664555	73.9899899	74.4688200	74.5265456	74.7884153
## [381]	75.0739288	75.5450883	75.7051703	75.7580885	76.0679917
## [386]	76.1455158	76.1593335	76.1720081	76.2424580	76.6934247
## [391]	76.7374556	76.9010961	77.0465797	77.2803286	77.4386946

```

## [396] 77.4857983 77.5598838 77.6321729 77.6494926 77.7238287
## [401] 77.9930538 78.1071137 78.4033612 78.4814226 78.6001619
## [406] 78.7204093 78.7579486 78.9508274 79.0317394 79.1154711
## [411] 79.1431364 79.2494753 79.3897981 79.4285390 79.6036003
## [416] 80.1107541 80.1874130 80.2368399 80.3518334 80.4838176
## [421] 80.5343593 80.5788630 80.6569045 80.6758902 80.6993679
## [426] 80.7475944 81.1023015 81.3923442 81.5478761 82.0806630
## [431] 82.2172561 82.2915251 82.5999403 82.6008907 83.3481600
## [436] 83.6791982 84.3044581 84.3493686 84.6304612 85.0405132
## [441] 85.1910415 85.6492415 86.0360071 86.1698720 86.2185266
## [446] 86.3745678 86.5782824 86.7522457 86.7909593 87.2811047
## [451] 87.4651826 87.5081669 87.5134537 87.9022302 88.0872580
## [456] 88.4953041 89.1094582 89.5216073 89.5344038 89.5725731
## [461] 89.6325409 89.8002232 90.8693706 90.9784924 91.1637314
## [466] 91.4348227 91.9639655 92.1148139 92.8925406 93.2828679
## [471] 93.4717328 93.4877335 93.6596891 94.1193423 94.7480365
## [476] 95.1895095 95.3423378 95.5300363 95.7966830 96.3749124
## [481] 97.0275266 97.0359420 97.0548227 97.1379662 97.2387708
## [486] 97.4826048 97.5660432 97.6540385 97.7107087 98.0772662
## [491] 98.3277722 98.3745992 98.4360295 98.9364734 99.9687850
## [496] 100.0874964 100.1623324 100.2242147 100.3420828 100.5168798
## [501] 100.6949656 100.7757178 100.8091187 101.0038754 101.1679643
## [506] 101.2319362 101.7768704 102.1206653 102.2339265 102.3467370
##
## $cuenta
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17
## [18] 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34
## [35] 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51
## [52] 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68
## [69] 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85
## [86] 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100 101 102
## [103] 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119
## [120] 120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136
## [137] 137 138 139 140 141 142 143 144 145 146 147 148 149 150 151 152 153
## [154] 154 155 156 157 158 159 160 161 162 163 164 165 166 167 168 169 170
## [171] 171 172 173 174 175 176 177 178 179 180 181 182 183 184 185 186 187
## [188] 188 189 190 191 192 193 194 195 196 197 198 199 200 201 202 203 204
## [205] 205 206 207 208 209 210 211 212 213 214 215 216 217 218 219 220 221
## [222] 222 223 224 225 226 227 228 229 230 231 232 233 234 235 236 237 238
## [239] 239 240 241 242 243 244 245 246 247 248 249 250 251 252 253 254 255
## [256] 256 257 258 259 260 261 262 263 264 265 266 267 268 269 270 271 272
## [273] 273 274 275 276 277 278 279 280 281 282 283 284 285 286 287 288 289
## [290] 290 291 292 293 294 295 296 297 298 299 300 301 302 303 304 305 306
## [307] 307 308 309 310 311 312 313 314 315 316 317 318 319 320 321 322 323
## [324] 324 325 326 327 328 329 330 331 332 333 334 335 336 337 338 339 340
## [341] 341 342 343 344 345 346 347 348 349 350 351 352 353 354 355 356 357
## [358] 358 359 360 361 362 363 364 365 366 367 368 369 370 371 372 373 374
## [375] 375 376 377 378 379 380 381 382 383 384 385 386 387 388 389 390 391
## [392] 392 393 394 395 396 397 398 399 400 401 402 403 404 405 406 407 408
## [409] 409 410 411 412 413 414 415 416 417 418 419 420 421 422 423 424 425
## [426] 426 427 428 429 430 431 432 433 434 435 436 437 438 439 440 441 442
## [443] 443 444 445 446 447 448 449 450 451 452 453 454 455 456 457 458 459
## [460] 460 461 462 463 464 465 466 467 468 469 470 471 472 473 474 475 476
## [477] 477 478 479 480 481 482 483 484 485 486 487 488 489 490 491 492 493

```

```
## [494] 494 495 496 497 498 499 500 501 502 503 504 505 506 507 508 509 510
```

## Problema 9


Simular un proceso Poisson no homogéneo con función de intensidad dada por  $\lambda(t) = \sin(t)$ .

**Solución:**

```
lambdat2<-function(t){sin(t)}

poissonnohomogeneo2<-function(lambdat,n,pic=T){
  lambda<-1
  TT<-rexp(n,lambda)
  s<-cumsum(TT)
  u<-runif(n)
  ss<-s[u<=lambdat(s)/lambda]
  Ns<-1:length(ss)
  if(pic==T){
    plot(ss,Ns,type="s",xlab="",ylab="N(t)",main="Proceso Poisson no homogéneo")
    return(list(ss,cuenta=Ns))
  }
}
poissonnohomogeneo(lambdat,50)
```

### Proceso Poisson no homogéneo



```
## [[1]]
## [1] 0.6914081 0.9043443 1.4365278 1.7501939 1.9322091 1.9980260
```

```
## [7] 2.2989980 2.9676263 3.2405007 3.4310868 3.4988366 3.7273121
## [13] 3.9999892 4.0010201 4.2733070 4.3031741 4.7122039 5.1088951
## [19] 5.6775954 5.8976370 6.1550852 6.2839354 6.3220672 6.5416872
## [25] 7.1505613 7.2952648 7.3534611 7.4709848 8.1688177 8.2291042
## [31] 8.2857901 8.3532873 8.6349998 8.6777249 8.8582651 8.8594023
## [37] 9.0631257 9.2091688 9.2969123 9.3990009 9.4814145 9.6195564
## [43] 9.7494766 9.8793862 10.0930023 10.3707470 10.4651960 10.9788685
## [49] 11.1383356 11.1846357
##
## $cuenta
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23
## [24] 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46
## [47] 47 48 49 50
```

## Problema 10

Una compañía de seguros tiene 1000 asegurados, cada uno de los cuales presentará de manera independiente una reclamación en el siguiente mes con probabilidad  $p = 0.09245$ . Suponiendo que las cantidades de los reclamos hechos son variables aleatorias normales con media 7000 y desviación estándar 5000, hagan simulación para estimar la probabilidad de que la suma de los reclamos exceda \$500,000.

**Solución:**

```
comp_seguros<-function(n_as,p,m,de){
  n_rec<-sum(rbinom(n,1,p))
  montos_rec<-rnorm(n_rec,m,de)
  tot_rec<-sum(montos_rec)
}

registro<-replicate(10000,comp_seguros(1000,0.09245,7000,5000))
p_exceder<-length(subset(registro,registro>500000))/10000
p_exceder
```

```
## [1] 0.9738
```

## Problema 11

Escribir una función para generar una mezcla de una distribución normal multivariada con dos componentes con medias  $\mu_1$ ,  $\mu_2$  y matrices de covarianzas  $S_1$ ,  $S_2$  respectivamente. Con el programa, generar una muestra de tamaño  $n = 1000$  observaciones de una mezcla 50% de una normal 4-dimensional con  $\mu_1 = (0, 0, 0, 0)$ ,  $\mu_2 = (2, 3, 4, 5)$ , y matrices de covarianzas  $S_1 = S_2 = I_4$ . Obtener los histogramas de las 4 distribuciones marginales

**Solución:**

```
r_normal_multi <-function(n,mu,Sigma){
  d <-length(mu)
  S <-svd(Sigma)
  Q <- S$u %*%diag(sqrt(S$d)) %*%t(S$v)
  Z <-matrix(rnorm(n*d),nrow=n, ncol=d)
  X <- Z %*% Q +matrix(mu,n,d,byrow=T)
  X
}
```

```
Sigma <-matrix(c(1, 0, 0,0, 0, 1, 0, 0, 0,0,1,0,0,0,0,1),byrow=T,nrow=4)
n<-1000
```

```
Y1<-r_normal_multi(n,c(0,0,0,0),Sigma = Sigma)
Y2<-r_normal_multi(n,c(2,3,4,5),Sigma = Sigma)
u <-runif(n)
k <-as.integer(u > 0.5)
Y <- k*Y1 + (1-k)*Y2
```


```
head(Y)
```

```
##           [,1]      [,2]      [,3]      [,4]
## [1,]  3.2830735  3.5285087  4.9023304  4.0769762
## [2,]  1.6699890  3.9726949  2.9523079  6.1592260
## [3,] -0.1819490  0.3476841  1.5646367  0.2669568
## [4,] -1.4745549 -2.0806043 -0.9958002 -0.3625205
## [5,]  1.1117781  1.1605891 -1.0435153  0.8648946
## [6,]  0.6607643 -0.5988266  1.2011336  0.4163359
```


```
par(mfrow=c(2,2))
```

```
hist(Y[,1],xlab = "",ylab = "",main = "Histograma Y1",breaks = 50)
hist(Y[,2],xlab = "",ylab = "",main = "Histograma Y2",breaks = 50)
hist(Y[,3],xlab = "",ylab = "",main = "Histograma Y3",breaks = 50)
hist(Y[,4],xlab = "",ylab = "",main = "Histograma Y4",breaks = 50)
```


**Histograma Y1**




**Histograma Y2**



**Histograma Y3**



**Histograma Y4**



## Problema 12

Distribución de Wishart. Suponer que  $M = X^T X$ , donde  $X$  es una matrix de  $n \times d$  de una muestra aleatoria de una distribución  $N_d(\mu, \Sigma)$ . Entonces  $M$  tiene una distribución Wishart con matriz de escala  $\Sigma$  y  $n$  grados de libertad, y se denota  $W \sim W_d(\Sigma, n)$ . Cuando  $d = 1$ , los elementos de  $X$  son una muestra aleatoria de una  $N(\mu, \sigma^2)$ , por lo que  $W_1(\sigma^2, n) \sim \sigma^2 \chi^2$ . Una forma de generar observaciones de una distribución Wishart, es generar muestras de multivariadas normales y calcular la matrix producto  $XX^T$ . Programar este método. Noten que este método es muy costoso porque se tienen que generar  $nd$  valores aleatorios normales para determinar las  $d(d+1)/2$  diferentes entradas de  $M$ .

```
Wishart_1<-function(n,mu,s){
  X<-r_normal_multi(n,mu,s)
  B<-X%*%t(X)
  return(B)
}

Wishart_ma<-function(tm,n,mu,s){
  replicate(tm,Wishart_1(n,mu,s))
}

#Ejemplo
ptm<-proc.time()
Wishart_ma(4,4,c(1,1),matrix(c(1, 0, 0,1),byrow=T,nrow=2))
```

```
## , , 1
##
##      [,1]      [,2]      [,3]      [,4]
## [1,] 6.671196 4.719887 2.686153 3.098848
## [2,] 4.719887 4.008668 1.767625 1.897355
## [3,] 2.686153 1.767625 1.107940 1.306311
## [4,] 3.098848 1.897355 1.306311 1.569544
##
## , , 2
##
##      [,1]      [,2]      [,3]      [,4]
## [1,] 1.078563 1.081820 1.670692 0.843163
## [2,] 1.081820 1.287782 2.288013 2.052639
## [3,] 1.670692 2.288013 4.437388 4.951810
## [4,] 0.843163 2.052639 4.951810 7.845726
##
## , , 3
##
##      [,1]      [,2]      [,3]      [,4]
## [1,] 10.961094 2.7814535 1.1524633 -1.8951714
## [2,] 2.781454 0.7062458 0.2849108 -0.5065118
## [3,] 1.152463 0.2849108 0.2523740 0.2464972
## [4,] -1.895171 -0.5065118 0.2464972 1.8421278
##
## , , 4
##
##      [,1]      [,2]      [,3]      [,4]
## [1,] 4.735999 4.519735 6.117271 3.704968
## [2,] 4.519735 4.438275 5.392535 3.255312
```



```
## [3,] 6.117271 5.392535 9.489329 5.785478
## [4,] 3.704968 3.255312 5.785478 3.528070
```

```
proc.time()-ptm
```

```
##      user  system elapsed
##      0.02    0.00    0.01
```

Un método más eficiente se basa en la descomposición de Bartlett: sea  $T = (T_{ij})$  una matriz triangular inferior de  $d \times d$  con entradas independientes que satisfacen:  $T_{ij} \sim N(0, 1)$  independientes para  $i > j$ ,  $T_{ii} \sim \sqrt{\chi_{n-i+1}^2}$ ,  $i = 1, \dots, d$ . Entonces la matrix  $A = TT'$  tiene una distribución  $W_d(I_d, n)$ . Para generar variables  $W_d(\Sigma, n)$ , obtener la descomposición de Cholesky  $\Sigma = LL'$ , donde  $L$  es triangular inferior. Entonces  $LAL' \sim W_d(\Sigma, n)$ .

## Problema 13

Las ocurrencias de huracanes que tocan tierra durante el fenómeno meteorológico “el Niño” se modelan como un proceso Poisson (ver Bove et al (1998)). Los autores aseguran que “durante un año del Niño, la probabilidad de dos o más huracanes haciendo contacto con tierra en los Estados Unidos es 28 %”. Encontrar la tasa del proceso Poisson.

### Solución:

Sea  $N$  el número de huracanes que tocan tierra en Estados Unidos, de manera que  $N$  tiene una distribución  $Po(\lambda)$ . Se sabe que  $Pr\{N \geq 2\} = 0.28$ , entonces

$$\begin{aligned} 0.28 &= Pr\{N \geq 2\} \\ &= 1 - Pr\{N < 2\} \\ &= 1 - Pr(N = 0) - Pr(N = 1) \\ &= 1 - \frac{\lambda^0 e^{-\lambda}}{0!} - \frac{\lambda^1 e^{-\lambda}}{1!}. \end{aligned}$$

Resolviendo para  $\lambda$  se tiene que  $\lambda = 1.042284919$ .

■

## Problema 14

Comenzando a mediodía, los comensales llegan a un restaurante de acuerdo a un proceso Poisson a una tasa de 5 clientes por minuto. El tiempo que cada cliente pasa comiendo en el restaurante tiene una distribución exponencial con media de 40 minutos, independiente de otros clientes e independiente de los tiempos de arribo. Encuentra la distribución así como la media y varianza, del número de comensales en el restaurante a las 2:00pm. Simular el restaurante para verificar los resultados obtenidos.

## Problema 15